

6.15~6.21工作Report

武晨曦

本周我基于已有的CoC产线，进行模型训练实验，并根据实验情况对NVIDIA的Alpamayo进行了消融实验

Qwen3.5微调

输入：四张环视图

消融对象：是否有CoC，是否输入历史轨迹，是否有真实图片

base model:Qwen3.5 2B

数据集：NVIDIA PhysicalAI-AV 20k子集

训练超参使用前期实验中结果较好的值：

Epoch = 3, batch size = 16, gpu_num = 4, learning rate = 4e-5

实验结果：

输入：	是否有CoC	1s Error(m) ↓	2s Error(m) ↓	3s Error(m) ↓	Avg, Error(m) ↓
images + history traj	×	0.031	0.181	0.500	0.237
images without history traj	×	0.886	2.196	3.594	2.225
no image, only history traj ①	×	0.046	0.246	0.643	0.312
images + history traj	√	0.029	0.183	0.496	0.236
images without history traj	√	0.874	2.115	3.441	2.143
NV Alpamayo 实际表现②					
images+history traj	√	0.066	0.403	1.083	0.514

注：①训练和评测时无图片，使用纯文本

②Alpamayo并未开源官方bench mark，我在测试集中挑选了844个场景进行轨迹预测，在Alpamayo论文中官方给出的数值为：3s minADE:0.273 m.

结论：

1. 不输入历史轨迹时，当前产线所生产的CoC对轨迹精度的提升较大
2. 输入历史轨迹后，模型会的输出会非常依赖历史轨迹，对图片信息的利用能力基本丧失，CoC对最终轨迹精度也几乎没有影响
3. VLM 直出方案当前3s ADE = 0.496 m ,与Alpamayo的0..273m尚有一定差距

基于结论2，我对NV的Alpamayo模型进行消融实验：

输入：	噪声形式	1s Error(m) ↓	2s Error(m) ↓	3s Error(m) ↓	Avg, Error(m) ↓
images+history traj	无	0.066	0.403	1.083	0.514
images+history traj	把图片替 换为噪声	0.059	0.391	1.002	0.484
images+history traj	对历史轨 迹加噪声	0.489	1.399	2.562	1.483
images+history traj	将历史轨 迹置为0	3.207	7.741	12.099	7.683

注：图片替换为噪声的方法为把模型的输入换为同样尺寸的随机张量，保存到本地可视化的效果类似于下图：



对历史轨迹加噪声的方法：原输入为 $[x_1, y_1, z_1 \dots \dots, x_{16}, y_{16}, z_{16}]$,对每个元素，以 x_i 为例，替换方法为：
 $x'_i = x_i + x_i \cdot a \cdot 0.15$, a 是取值范围为 $[-1,1]$ 的随机数

结论：

NV的Alpamayo在出轨迹时，严重依赖历史轨迹，对图片信息认知基本丧失

产生的问题：

基于上述实验结果，我遇到了新的问题：如何在保持预测轨迹精度的同时，让模型尽可能依赖于图片信息而不是历史轨迹？

解决方案：

进行两阶段训练

一阶段：参考RecogDrive的方法，在PhysicalAI-AV数据集上做一组VQA数据，使用该VQA数据与不含历史轨迹的出轨迹数据混合训练模型

二阶段：降低学习率，进行出轨迹的微调，做消融实验

下周（6.22~6.28）计划：

- 1.标注VQA数据（20k数据集，耗时约30h，远程进行中）
- 2.进行两阶段训练实验