

工作周报

2026.5.10 武晨曦

CoT标注流水线设计

为了训练一个CoT标注模型，我们在NVIDIA PhysicalAI-AV数据集上设计了一套自动标注流水线，以获取高质量CoT数据。

流水线设计如下：

1.关键帧获取

数据集的每一个clip时长为8s，我们首先需要获取这8s内对驾驶决策产生决定性影响的关键帧。具体方法为：将第4s到第8s的数据以2hz频率采样，得到9张前视图，同时将这个clip的轨迹可视化，并标注时间节点（例如第4s时车辆在轨迹的哪个点），将这10张图片送入Qwen 3.5,让模型选出关键帧时间点。

2.CoT获取+评测

基于1得到的关键帧，我们使用Alpamayo 1.5模型推理得到CoT，随后进入评测环节。

我的评测目前有两种方案，输入为：关键帧时刻的Left Side,Front Wide,Front Tele,Right Side四张视图，加上这一个clip轨迹的可视化图像，与1不同的是，我们在这张图像上标注的是关键帧结点车辆的位置。两种评测方案具体为：

(1) “合格”或者“不合格”二元分类。

我们询问Qwen 3.5，CoT是否清晰说出决定车辆未来轨迹走向的核心主导原因。

(2) 打分制，从3个方面评判，满分为100分，最低输出1分（防止分数提取异常），三个方面各占33分：

- CoT的驾驶决策与未来轨迹是否一致
- CoT的架势决策是否合理
- 驾驶决策的核心原因是否与事实相符


实验进展

我们在NVIDIA开源的关键子集（1180 clips）上展开实验，受限于算法效率，只对子集的部分数据展开实验。

结果如下：

1.二元分类实验


CoT Verification Results



在397个clip中，1.1%的数据评测失效，模型挑选出了12.7%的不合格数据。

2.打分制实验

CoT Score Distribution



在194个clip中，1.5%的打分结果不合输出规则，36.6%的数据质量较低，85分以上的高质量数据占比为46.9%。

人工核验

我对于低质量数据展开人工核验，发现其CoT确实大量存在主因错误、CoT与未来轨迹不符的情况。误判与遗漏的比率需要进一步核验。

存在的问题与下周计划

- 1. 问题：当前算法效率较低，目前我使用的是Qwen3.5 9B模型筛选关键帧并评测，评测效率只有1clip/min。
计划：使用1b~2b的模型并关闭思考模式进行初步筛选，再使用更大模型精细选择。并优化算法效率，提高GPU使用率。

2. 问题：评测并不是严谨的闭环，大模型评测必然存在误判与遗漏问题。
计划：调研更优的评测方法。